

# Segmentación de imágenes del hueso cortical con umbrales multinivel mediante algoritmos de optimización metaheurísticos

1<sup>st</sup> Fernando Ramírez

*Escuela de Ingeniería Informática*

*Universidad de Valparaíso*

Valparaíso, Chile

fernando.ramirezs@postgrado.uv.cl

2<sup>nd</sup> Emilio Flores

*Escuela de Ingeniería Informática*

*Universidad de Valparaíso*

Valparaíso, Chile

emilio.flores@postgrado.uv.cl

**Abstract—Resumen del trabajo: motivación e introducción básica del contexto. Problema general y forma de abordarlo. Principales resultados y aportes al estado del arte. Máx. 250 palabras. Sin referencias.**

**Index Terms—**término clave 1, término clave 2, término clave 3, término clave 4, término clave 5

## I. INTRODUCCIÓN

El hueso cortical, también conocido como hueso compacto, representa una forma predominantemente sólida de tejido óseo que conforma cerca del 80% del esqueleto humano según las mediciones tomadas por diversos estudios [?]. Esta componente del sistema óseo tiene importancia crítica en funciones vitales como la protección de órganos internos, incluyendo el cerebro, pulmones y médula espinal. Además, ofrece soporte estructural al cuerpo y facilita la movilidad al proporcionar puntos de anclaje para los músculos y articulaciones. Por lo tanto, la integridad y salud del hueso cortical son vitales para el bienestar del individuo. Su estado también puede ser un indicador crucial para el diagnóstico y el tratamiento de diversas enfermedades que afectan al sistema óseo, tales como la osteoporosis, fracturas y ciertos tipos de cáncer óseo [?].

Para la segmentación de imágenes médicas del hueso cortical, se trata de un campo interdisciplinario. Principalmente, la medicina y la radiología son fundamentales para entender las necesidades clínicas y las implicaciones de los algoritmos de segmentación en el diagnóstico y tratamiento. Además, la informática juega un rol crucial en el desarrollo y aplicación de software y sistemas que pueden manejar y analizar grandes conjuntos de datos de imágenes médicas.

Para determinar el estado del hueso cortical, uno de los indicadores más útiles es el Índice de Porosidad (PI). Este índice se cuantifica mediante técnicas avanzadas de resonancia magnética, específicamente utilizando tiempos de eco ultracortos (UTE) [?]. La singularidad de la técnica UTE radica en su capacidad para adquirir imágenes en dos tiempos distintos, lo

cual posibilita una evaluación comparativa de la intensidad de la señal entre el agua libre y el agua ligada en el hueso. Esto es crucial para entender la microestructura del hueso y, por lo tanto, su salud general [?], [?].

Una forma efectiva de comparar estas señales de agua es mediante la segmentación de la imagen para extraer la región de interés, en este caso, el hueso cortical [?]. Sin embargo, la segmentación se convierte en un desafío cuando las imágenes presentan bordes poco definidos o iluminación vaga, especialmente en pacientes patológicos. Estas dificultades requieren técnicas de análisis de imágenes más avanzadas para determinar los bordes correspondientes de la región de interés.

La exactitud en la medición del Índice de Porosidad depende en gran medida de la precisión con que se pueda segmentar la región de interés en las imágenes médicas, en este caso, el hueso cortical [?]. Sin embargo, este proceso de segmentación se torna especialmente desafiante en situaciones donde las imágenes tienen bordes difusos, ruido de fondo o iluminación inconsistente. Estos problemas son más prominentes en imágenes obtenidas de pacientes con patologías óseas, donde las irregularidades en el tejido óseo pueden comprometer la calidad de la imagen [?].

En el contexto de los desafíos inherentes a la segmentación de imágenes del hueso cortical, nuestra principal motivación radica en la necesidad de mejorar la precisión diagnóstica y la eficacia del tratamiento en enfermedades óseas. Reconocemos que las técnicas actuales pueden enfrentar limitaciones significativas, especialmente cuando se trata de imágenes de baja calidad o de pacientes con patologías complejas. Estas limitaciones no sólo afectan la calidad del diagnóstico, sino que también pueden tener consecuencias graves en el tratamiento y en el bienestar a largo plazo del paciente.

En el ámbito social de la segmentación de imágenes médicas del hueso cortical, varios actores juegan roles críticos. Entre ellos se incluyen profesionales médicos como radiólogos y cirujanos ortopédicos, quienes buscan herramientas diagnósticas precisas y eficientes. Los investigadores y científicos aspiran a innovar en métodos de segmentación más avanzados, mientras que los pacientes son los beneficiarios finales que se verán

\*Entrega para el curso de Experimentación en Ingeniería, Doctorado de Ingeniería Informática Aplicada, Escuela de Ingeniería Informática, Universidad de Valparaíso, Chile.

impactados por diagnósticos y tratamientos más acertados. Además, administradores de instituciones de salud y reguladores buscan soluciones que equilibren eficiencia, costo y cumplimiento de estándares.

La revisión de la literatura científica revela que gran parte de la investigación existente se ha centrado en la segmentación de imágenes cerebrales, cardíacas o de tumores, con pocos estudios abordando las particularidades y desafíos asociados con la segmentación de imágenes del hueso cortical. Esta brecha representa tanto un problema de diseño como de conocimiento. En términos de diseño, la falta de algoritmos eficientes y precisos para esta tarea específica limita la capacidad de los profesionales médicos para realizar diagnósticos y tratamientos efectivos. Desde una perspectiva de conocimiento, no comprender plenamente cómo adaptar o crear algoritmos que puedan manejar las peculiaridades de la segmentación de imágenes del hueso cortical impide el avance de la informática médica como disciplina.

La principal contribución es el desarrollo de una metodología innovadora que emplea algoritmos de optimización metaheurísticos inspirados en la naturaleza. A diferencia de las técnicas convencionales de segmentación, nuestro enfoque se adapta de manera dinámica a las variabilidades y imperfecciones en las imágenes médicas, permitiendo una segmentación más rápida y precisa de la región de interés, en este caso, el hueso cortical. Este aumento en la precisión y la eficiencia en la segmentación tiene el potencial de diagnósticos más acertados y tratamientos personalizados y efectivos.

La propuesta incorpora ocho diferentes técnicas de optimización, para maximizar la eficiencia y la precisión en la segmentación de imágenes. Estas técnicas son: Particle Swarm Optimization (PSO), Crow Search Algorithm (CSA), Honey Badger Algorithm (HBA), Harris Hawk Optimization (HHO), Orca Predator Optimization (OPO), Reptile Search Algorithm (RSA), y Gray Wolf Optimization (GWO). La elección de estas siete técnicas no es arbitraria. Cada una ha mostrado resultados notables en aplicaciones previas que abarcan desde ingeniería hasta ciencias, incluyendo la biomedicina. Además, estas técnicas ofrecen diversos mecanismos de búsqueda y optimización, lo que nos permite explorar un espectro más amplio de soluciones potenciales. Algunas, como el Particle Swarm Optimization y el Gray Wolf Optimization, son particularmente eficaces para explorar el espacio de soluciones en problemas complejos. Otras, como el Honey Badger Algorithm y el Harris Hawk Optimization, están diseñadas para adaptarse dinámicamente a entornos cambiantes, lo que es especialmente útil en la segmentación de imágenes médicas donde las condiciones pueden variar sustancialmente.

En la definición del estudio de validación del tratamiento, Con este estudio, aspiramos a contribuir en el ámbito de la segmentación de imágenes médicas, demostrando que los algoritmos metaheurísticos bioinspirados no sólo son viables, sino también altamente eficientes y eficaces para resolver problemas complejos en este campo. Creemos que los hallazgos de este trabajo fomentaran la adopción de estas técnicas avanzadas en la práctica clínica diaria, mejorando la calidad

del diagnóstico y tratamiento de los pacientes.

## II. TRABAJOS RELACIONADOS VERSION 4

La segmentación de imágenes médicas es un campo de investigación crucial que ha experimentado avances significativos gracias a la aplicación de algoritmos de optimización metaheurísticos. Estos algoritmos, inspirados en comportamientos y estrategias naturales, han demostrado ser herramientas eficaces y versátiles para abordar problemas complejos en la informática y la optimización. Kumar et al. [?] destacan la importancia de estos métodos en resolver múltiples problemas, subrayando su capacidad para combinar eficacia y versatilidad. Abualigah et al. [?] proporcionan un análisis exhaustivo sobre la relevancia de los algoritmos metaheurísticos en la segmentación de imágenes multinivel, utilizando métricas estándar como la función de fitness, la relación señal-ruido (PSNR) y el Índice de Similitud Estructural (SSIM) para evaluar su eficacia. Ma et al. [?] también contribuyen a esta discusión, resaltando la capacidad de estos algoritmos para mejorar la precisión y calidad en la segmentación de imágenes médicas.

En 2019, se realizaron importantes contribuciones en la optimización de algoritmos para la segmentación y clasificación de imágenes. Ahilan et al. [?] destacaron por la optimización de enjambres de partículas de orden fraccional darwiniano para la segmentación y compresión de imágenes médicas. Muhammad Attique Khan [?] desarrolló un método optimizado para la clasificación de enfermedades en manzanas, mientras que Xiaoli Bao [?] introdujo un algoritmo híbrido para la segmentación de imágenes a color. Heming Jia [?] optimizó la segmentación de imágenes satelitales con un algoritmo basado en la optimización dinámica de Harris Hawks.

En 2020, Dalia Yousri [?] mejoró la robustez en optimización global y segmentación de imágenes con una variante del algoritmo de polinización de flores. Mohamed Abdel-Basset [?] abordó la segmentación de imágenes de rayos X del pecho utilizando un enfoque híbrido, y Xiaopeng Wang [?] presentó un algoritmo basado en la teoría del multi-verso para la segmentación de imágenes.

En 2021, Sanjoy Chakraborty y Essam H. Houssein [?], [?] se enfocaron en la segmentación de imágenes médicas. Laith Abualigah [?] aplicó una versión mejorada del algoritmo de optimización aritmética a imágenes CT de COVID-19. K.P. Baby Resma [?] exploró el algoritmo de Optimización de Manada de Krill, y Dong Zhao y Rajarshi Bandyopadhyay [?], [?] presentaron variantes de algoritmos para la segmentación multiumbral de imágenes y de imágenes de resonancia magnética del cerebro, respectivamente.

En 2022, se destacaron Khalid M. Hosny con COVID-HHOA para la segmentación de imágenes médicas [?], S. Navaneetha Krishnan con el algoritmo MSFO para la mejora de imágenes médicas [?], y Debao Chen con el Poplar Optimization Algorithm [?].

Finalmente, en 2023, Wei Zhu [?] presentó una mejora para la segmentación de imágenes de tumores cerebrales, Panli Zhang [?] introdujo un algoritmo para segmentación

con múltiples umbrales, Marwa M. Emam [?] desarrolló una técnica para la optimización global y segmentación de imágenes de resonancia magnética del cerebro, y N. Priyadharshini [?] propuso un método híbrido para la detección temprana de melanoma.

Desde 2019 hasta 2023, diversos estudios han contribuido significativamente al campo de la segmentación y clasificación de imágenes, implementando algoritmos de optimización para mejorar la eficacia y eficiencia en el procesamiento y análisis de imágenes en diversos campos.

A pesar de los avances significativos en la segmentación de imágenes médicas gracias a la aplicación de algoritmos metaheurísticos, aún existen desafíos y oportunidades de investigación en áreas específicas. Una de estas áreas es la segmentación de imágenes del hueso cortical, un tema que ha recibido menos atención en comparación con otros tejidos y órganos.

La habilidad de los resonadores magnéticos clínicos para generar secuencias de eco ultracorto (UTE) y capturar señales procedentes del tejido óseo cortical ha convertido la segmentación del hueso cortical en una herramienta diagnóstica con potencial para evaluar la calidad y la salud ósea [?]. En este contexto, el desarrollo e implementación de metodologías precisas y robustas para la segmentación del hueso cortical se torna imprescindible, brindando un soporte crucial para un diagnóstico clínico exacto y fiable.

se hace evidente la necesidad de enfoques innovadores y personalizados que puedan adaptarse a las características del hueso cortical. Los algoritmos metaheurísticos, con su capacidad para explorar espacios de soluciones complejas y encontrar óptimos globales, representan una opción prometedora para abordar estos desafíos.

### III. DEFINICIÓN DEL PROBLEMA

La segmentación de imágenes ha sido ampliamente investigada convirtiendo imágenes a color o en escala de grises en imágenes binarias determinando un umbral en la intensidad de píxeles de la imagen [?]. Existen dos tipos de umbralización, una de ellas es binaria y la otra es multinivel. La umbralización binaria consiste en dividir la imagen en dos regiones  $R_1$  y  $R_2$  a partir de un umbral ( $th$ ), en este caso se asigna cada píxel  $\rho$  a una de las dos regiones como se muestra:

$$\rho \in R_1 \text{ if } 0 \leq \rho < th, \quad (1)$$

$$\rho \in R_2 \text{ if } th \leq \rho < L-1, \quad (2)$$

L corresponde al máximo nivel de intensidad. Por otro lado, la umbralización multinivel consiste en dividir las imágenes en diferentes regiones utilizando más de un umbral como se muestra:

$$\rho \in R_1 \text{ if } 0 \leq \rho < th_1 \quad (3)$$

$$\rho \in R_2 \text{ if } th_1 \leq \rho < th_2 \quad (4)$$

$$\rho \in R_i \text{ if } th_i \leq \rho < th_{i+1} \quad (5)$$

$$\rho \in R_k \text{ if } th_{k-1} \leq \rho < L-1 \quad (6)$$

En donde  $\{th_1, th_2, \dots, th_k\}$  corresponde a un vector que representa los diferentes valores de los umbrales.

Para determinar estos umbrales se utilizan diversos métodos, entre estos destaca la entropía de la imagen, que representa la compacidad y separación entre las clases [?]. Uno de estos métodos es la entropía de Kapur, que ha sido ampliamente utilizada para encontrar los valores de umbrales óptimos, maximizando la entropía. Para el caso binario se muestra:

$$th^* = \max(F_{kapur}(th)) \quad (7)$$

$$F_{kapur}(th) = A_0 + A_1 \quad (8)$$

$$A_0 = - \sum_{i=0}^{th-1} \frac{P_i}{\omega_0} \ln \frac{P_i}{\omega_0}, \quad A_1 = - \sum_{i=th}^{L-1} \frac{P_i}{\omega_0} \ln \frac{P_i}{\omega_0} \quad (9)$$

donde  $P_i$  es la probabilidad de un nivel de gris  $i$ , que puede ser representado como:

$$P_i = \frac{f_i}{\sum_{i=0}^{L-1} f_i} \quad (10)$$

donde  $f_i$  es la frecuencia en el nivel de gris  $i$ . Por otro lado, se tiene que:

$$\omega_0 = \sum_{i=0}^{th-1} P_i, \omega_1 = \sum_{i=th}^{L-1} P_i \quad (11)$$

En el caso de una umbralización multinivel, se muestra:

$$F_{kapur}(th) = A_0 + A_1 + \dots + A_{k-1} \quad (12)$$

$$A_0 = - \sum_{i=0}^{th_1-1} \frac{P_i}{\omega_0} \ln \frac{P_i}{\omega_0}, \quad \omega_0 = \sum_{i=0}^{th_1-1} P_i \quad (13)$$

$$A_1 = - \sum_{i=th_1}^{th_2-1} \frac{P_i}{\omega_1} \ln \frac{P_i}{\omega_1}, \quad \omega_1 = \sum_{i=th_1}^{th_2-1} P_i \quad (14)$$

$$A_2 = - \sum_{i=th_2}^{th_3-1} \frac{P_i}{\omega_2} \ln \frac{P_i}{\omega_2}, \quad \omega_2 = \sum_{i=th_2}^{th_3-1} P_i \quad (15)$$

$$A_n = - \sum_{i=th_{k-1}}^{L-1} \frac{P_i}{\omega_n} \ln \frac{P_i}{\omega_n}, \quad \omega_n = \sum_{i=th_{k-1}}^{L-1} P_i \quad (16)$$

El símbolo  $th$  es un vector que contiene todos los valores de los umbrales. además del método de la entropía de Kapur, se implementó el método de Otsu.

$$f(\mathbf{t}) = \sum_{i=1}^{k+1} w_i (\mu_i - \mu_T)^2 \quad (17)$$

$$\text{donde:} \quad (18)$$

$$\mathbf{t} = (t_1, t_2, \dots, t_k) \in \mathbb{Z}^k \text{ es el vector de umbrales} \quad (19)$$

$$k = \text{dimensión de la imagen} \quad (20)$$

$$\mu_T = \sum_{p=0}^{255} ph(p) \text{ es la media total de la imagen} \quad (21)$$

$$h(p) = \text{histograma normalizado el valor de píxel } p \quad (22)$$

$$w_i = \sum_{p=l_i}^{u_i} h(p) \text{ es el peso de la clase } i \quad (23)$$

$$\mu_i = \frac{1}{w_i} \sum_{p=l_i}^{u_i} ph(p) \text{ es la media de la clase } i \quad (24)$$

$$l_i = \begin{cases} 0 & \text{si } i = 1 \\ t_{i-2} & \text{en otro caso} \end{cases} \quad (25)$$

$$u_i = t_i \text{ para } i = 1, 2, \dots, k \quad (26)$$

$$u_{k+1} = 256 \quad (27)$$

#### IV. ALGORITMOS METAHEURÍSTICOS

En esta sección, la umbralización multinivel es realizada mediante algoritmos metaheurísticos maximizando la entropía de Kapur como sigue:

$$\max(F_{\text{kapur}}(th)) \quad (28)$$

$$th \in 0 \leq th_i \leq 255 \quad (29)$$

En donde  $i = [1, 2, \dots, n]$ , siendo  $n$  la cantidad de umbrales.

##### A. Bald Eagle Search

El algoritmo Bald Eagle Search (BES) propuesto por Al-sattar et al. [?], es un algoritmo metaheurístico bioinspirado que imita la estrategia de caza o el comportamiento social inteligente de las águilas calvas mientras cazan peces.

La etapa de identificación del área se relaciona con el águila calva cuando realiza la búsqueda de la mejor posición  $P$  para cazar comida (select space). Esta etapa se representa matemáticamente como:

$$P_{\text{new}} = P_{\text{best}} + \alpha r (P_{\text{mean}} - P_i) \quad (30)$$

$$(31)$$

Una vez seleccionada la mejor posición en el espacio, el águila calva realiza diferentes movimientos en espiral para aumentar la velocidad del proceso de búsqueda de comida, a esta etapa se le denomina búsqueda dentro del área (search space) y se representa matemáticamente como:

$$P_{\text{new}} = P_i + y(i)(P_i - P_{i+1}) + x(i)(P_i - P_{\text{mean}}) \quad (32)$$

$$x(i) = \frac{xr_i}{\max(|xr|)} \quad , \quad y(i) = \frac{yr_i}{\max(|yr|)} \quad (33)$$

$$xr(i) = r(i) \cdot \sin(\theta(i)) \quad , \quad yr(i) = r(i) \cdot \cos(\theta(i)) \quad (34)$$

$$\theta(i) = a \cdot r \cdot \text{rnd} \quad , \quad r(i) = \theta(i) + R \cdot \text{rnd} \quad (35)$$

La última etapa del algoritmo BES corresponde a la selección y ataque de la presa, denominada arremetida (swoop). La arremetida consiste en mover todos los mejores puntos hacia el objetivo, matemáticamente esto se expresa como:

$$P_{\text{new}} = \text{rnd} \cdot P_{\text{best}} + x1(i)(P_i - c1 \cdot P_{\text{mean}}) \quad (36)$$

$$+ y1(i)(P_i - c2 \cdot P_{\text{best}}) \quad (37)$$

$$x1(i) = \frac{xr_i}{\max(|xr|)} \quad , \quad y1(i) = \frac{yr_i}{\max(|yr|)} \quad (38)$$

$$xr(i) = r(i) \cdot \sinh(\theta(i)) \quad , \quad yr(i) = r(i) \cdot \cosh(\theta(i)) \quad (39)$$

##### B. Harris Hawk Optimization

El algoritmo Harris Hawk Optimization (HHO), es un algoritmo bioinspirado propuesto por Heidari et al. [?] basado en el comportamiento de Harris Hawks. El algoritmo fue modelado mediante las fases de exploración y explotación. En la fase de exploración, el Harris Hawk puede detectar y seguir a su presa mediante sus poderosos ojos. En el HHO el Harris Hawk se puede mantener de manera aleatoria en algunas locaciones y esperar a detectar una presa basado en su estrategia. Si se considera una chance igual  $q$  para cada estrategia posado basado en la posición de los miembros de su familia, se puede modelar como una condición  $q < 0.5$ , o posado en una posición aleatoria en los árboles como  $q \geq 0.5$ , como se muestra:

$$X(t+1) =$$

$$\begin{cases} X_{\text{rnd}}(t) - r_1 |X_{\text{rnd}}(t) - 2r_2 X(t)|, q \geq 0.5 \\ X_{\text{rab}}(t) - X_m(t) - r_3(LB + r_4(UB - LB)), q < 0.5 \end{cases} \quad (40)$$

La posición promedio se puede calcular mediante:

$$X_m(t) = \frac{1}{N} \sum_{i=1}^N X_i(t) \quad (41)$$

En la transición de la exploración a la explotación, cuando una presa escapa pierde energía, esta pérdida se modela como:

$$E = 2E_0(1 - \frac{t}{T}) \quad (42)$$

El parámetro  $E$  indica la energía de escape de la presa y  $T$  es el máximo número de iteraciones. Por otro lado,  $E_0$  es un parámetro aleatorio que oscila entre  $(-1, 1)$  para cada iteración.

Por otro lado, la fase de explotación se divide en dos, asedio suave y asedio duro. En el asedio suave se deben cumplir las condiciones de  $r \geq 0.5$  y  $|E| \geq 0.5$ , la presa intenta escapar

por algunos saltos aleatorios pero finalmente no puede. Esto se modela como:

$$\begin{aligned} X(t+1) &= \Delta X(t) - E|JX_{rabb}(t) - X(t)| \\ \Delta X(t) &= X_{rabb}(t) - X(t) \end{aligned} \quad (43)$$

En el asedio duro, se debe cumplir  $r \geq 0.5$  y  $|E| < 0.5$ , la presa está cansada para escapar. En este caso, la posición se actualiza según:

$$X(t+1) = X_{rabb}(t) - E|\Delta X(t)| \quad (44)$$

### C. Orca Predator Algorithm

El algoritmo Orca Predator (OPA) propuesto por Jiang et al. [?] es un algoritmo metaheurístico bioinspirado en el comportamiento de las Orcas. Las Orcas son seres vivos carnívoros muy inteligentes en la familia de delfines, ellos viven en familias con aproximadamente 30 miembros. Las Orcas se comunican entre ellas con sonidos, en donde coordinan sus movimientos para pastorear peces, llevarlos hacia la superficie y finalmente encerrarlos. El modelo del grupo de Orcas puede nadar en  $1-D$ ,  $2-D$ ,  $3-D$  o en un espacio extradimensional. Esto se define como:

$$X = [x1, x2, \dots, xN] = \begin{bmatrix} x1,1 & x1,2 & \dots & x1,D \\ x2,2 & x2,2 & \dots & x2,D \\ \vdots & \vdots & \vdots & \vdots \\ xN,1 & xN,2 & \dots & xN,D \end{bmatrix} \quad (45)$$

El movimiento de las Orcas pastoreando peces se puede modelar mediante la velocidad de movimiento como sigue:

$$\begin{aligned} v_{chase,1,i}^t &= a(dx_{best}^t - F(bM^t + cx_i^t)) \\ v_{chase,2,i}^t &= ex_{best}^t - x_i^t \\ M &= \frac{\sum_{i=1}^N x_i^t}{N} \\ c &= 1 - b \end{aligned} \quad (46)$$

$$\begin{cases} x_{chase,1,i}^t = x_i^t + v_{chase,1,i}^t, & \text{if } rand > q \\ x_{chase,2,i}^t = x_i^t + v_{chase,2,i}^t, & \text{if } rand \leq q \end{cases}$$

El rodeo de presas se realiza mediante la posición de tres Orcas seleccionadas al azar, y luego su posición se puede determinar como:

$$\begin{aligned} x_{chase,3,i}^t &= x_{j1,k}^t + u \times (x_{j2,k}^t - x_{j3,k}^t) \\ u &= 2 \times (rand - \frac{1}{2}) \times \frac{Max_{iter} - t}{Max_{iter}} \end{aligned} \quad (47)$$

El ajuste de posición se determina comparando los mejores valores obtenidos en la función de ajuste, esto se modela como:

$$\begin{cases} x_{chase,i}^t = x_{chase,i}^t, & \text{if } f(x_{chase,i}^t) < f(x_i^t) \\ x_{chase,i}^t = x_i^t, & \text{if } f(x_{chase,i}^t) \geq f(x_i^t) \end{cases} \quad (48)$$

En donde  $f(x_{chase,i}^t)$  corresponde al valor de la función de ajuste en  $x_{chase,i}^t$  y  $f(x_i^t)$  corresponde al valor de la función de ajuste en  $x_i^t$ .

El ataque de las Orcas se puede modelar como sigue:

$$\begin{aligned} v_{attack,1,i}^t &= \frac{(x_{first}^t + x_{second}^t + x_{third}^t + x_{four}^t)}{4 - x_{chase,i}^t} \\ v_{attack,2,i}^t &= \frac{(x_{chase,j1}^t + x_{chase,j2}^t + x_{chase,j3}^t)}{3 - x_i^t} \\ v_{attack,i}^t &= x_{chase,i}^t + g1 \times v_{attack,1,i}^t + g2 \times v_{attack,2,i}^t \end{aligned} \quad (49)$$

### D. Crow Search Algorithm

El algoritmo Crow Search (CSA) propuesto inicialmente por Askarzadeh et al. [?], es un algoritmo metaheurístico bioinspirado en el comportamiento de los Crows. Los Crows son consideradas las aves más inteligentes, observan a otras aves, observan donde esconden su comida, y las roban cuando no están. De hecho, utilizan su propia experiencia de haber sido ladrones para predecir el comportamiento de un ladrón y pueden determinar el camino más seguro para proteger sus tesoros contra el robo. El primer paso está asociado a la posición y se modela como:

$$\begin{aligned} x^{i,iter} &= [x_1^{i,iter}, x_2^{i,iter}, \dots, x_d^{i,iter}] \\ x^{i,iter+1} &= x^{i,iter} + r_i \times f^{i,iter} \times (m^{j,iter} - x^{i,iter}) \end{aligned} \quad (50)$$

Crow j sabe que crow i lo está siguiendo. Como resultado, para proteger su caché contra el robo, el cuervo j engañará al cuervo i yendo a otra posición del espacio de búsqueda. Esto se modela como:

$$\begin{aligned} x^{i,iter+1} &= \\ \begin{cases} x^{i,iter} + r_i f^{i,iter} (m^{j,iter} - x^{i,iter}) & r_j \geq AP^{i,iter} \\ \text{a random position} & \text{otherwise} \end{cases} \end{aligned} \quad (51)$$

### E. Gray Wolf Optimization

El algoritmo Gray Wolf Optimization (GWO) originalmente propuesto por Mirjalili et al. [?], es un algoritmo metaheurístico bioinspirado en el comportamiento de los Gray Wolf, quienes son considerados superdepredadores, viven en manada y el tamaño grupal suele ir desde los 5 hasta los 12 individuos. Matemáticamente, se considera una jerarquía dentro de la manada, en donde los valores de las soluciones se almacenan en orden, en  $\alpha$ ,  $\beta$  y  $\delta$ , como primero, segundo y tercero respectivamente. El resto de soluciones se almacenan en  $\omega$ . El algoritmo GWO almacena la caza guiados por  $\alpha$ ,  $\beta$  y  $\delta$  mientras que  $\omega$  sigue a las otras variables.

La fase de caza comienza con rodear las presas, esto se modela como:

$$\begin{aligned} \vec{D} &= |\vec{C} \times \vec{X}_p(t) - \vec{X}(t)| \\ \vec{X}(t+1) &= \vec{X}_p(t) - \vec{A} \times \vec{D} \end{aligned} \quad (52)$$

En donde  $\vec{A}$  y  $\vec{C}$  son coeficientes del vector y  $\vec{X}$  es la posición. La caza es guiada por el alfa, el beta y delta no

suelen participar. Matemáticamente, se asume que alfa, beta y delta tienen el mejor conocimiento sobre la posición de las presas. Luego, se almacenan las tres mejores soluciones y se les obliga a los demás agentes a moverse y actualizar sus posiciones acorde a las mejores soluciones.

$$\begin{aligned}\vec{D}_\alpha &= |\vec{C}_1 \times \vec{X}_\alpha - \vec{X}|, \vec{D}_\beta = |\vec{C}_1 \times \vec{X}_\beta - \vec{X}| \\ \vec{D}_\delta &= |\vec{C}_1 \times \vec{X}_\delta - \vec{X}| \\ \vec{X}_1 &= \vec{D}_\alpha - \vec{A}_1 \times (\vec{D}_\alpha), \vec{X}_2 = \vec{D}_\beta - \vec{A}_2 \times (\vec{D}_\beta) \\ \vec{X}_3 &= \vec{D}_\delta - \vec{A}_3 \times (\vec{D}_\delta) \\ \vec{X}(t+1) &= \frac{\vec{X}_1 + \vec{X}_2 + \vec{X}_3}{3}\end{aligned}\quad (53)$$

#### F. Honey Badger Algorithm

El algoritmo Honey Badger Algorithm (HBA) originalmente propuesto por Hashim et al. [?], es un algoritmo metaheurístico bioinspirado basado en el comportamiento de los Honey Badger. El Honey Badger realiza seguimientos al pájaro guía de la miel, también puede oler y excavar aquellos lugares en donde se haya miel. El pájaro guía de la miel no tiene la capacidad de excavar para encontrar la miel, por otro lado el Honey Badger si puede excavar, es común que tanto el pájaro de la miel como el Honey Badger compartan la recompensa. La población de soluciones candidatas se modela como:

$$\begin{aligned}\text{Population of candidates solutions} = \\ \begin{bmatrix} x_{1,1} & x_{1,2} & \dots & x_{1,D} \\ x_{2,1} & x_{2,2} & \dots & x_{2,D} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n,1} & x_{n,2} & \dots & x_{n,D} \end{bmatrix}\end{aligned}\quad (54)$$

La intensidad está relacionada con el poder de concentración de la presa y la distancia entre este y el  $i$ th Honey Badger. La intensidad del olor de la presa es representada mediante  $I_i$ , si el olor es alto el movimiento será rápido y viceversa. Esto se define como:

$$\begin{aligned}I_1 &= r_2 \times \frac{S}{4\pi d_i^2} \\ S &= (x_i - x_{i+1})^2 \\ d_i &= x_{prey} - x_i\end{aligned}\quad (55)$$

$S$  representa el poder de concentración,  $d_i$  denota la distancia entre la presa y el  $i$ th Honey Badger. Por otro lado, el factor de densidad  $\alpha$  controla la aleatorización del tiempo variante para asegurar la transición de la exploración a la explotación, como se muestra:

$$\alpha = C \times \exp\left(\frac{-t}{t_{max}}\right)\quad (56)$$

En la fase de excavación el Honey Badger realiza un movimiento cardioide, como sigue:

$$\begin{aligned}x_{new} &= x_{prey} + F \times \beta \times Ix_{prey} + \\ &F \times r_3 \times \alpha \times d_i \times [\cos(2\pi r_4) \times [1 - \cos(2\pi r_5)]]\end{aligned}\quad (57)$$

$x_{prey}$  corresponde a la posición de la presa,  $r_3$ ,  $r_4$  y  $r_5$  son números aleatorios entre 0 y 1.  $F$  actúa como una flag que altera la dirección de búsqueda, como sigue:

$$F = \begin{cases} 1, & \text{if } r_6 \leq 0.5 \\ -1 & \text{else} \end{cases}\quad (58)$$

$r_6$  es un número aleatorio entre 0 y 1. Finalmente, la posición es actualizada por el pájaro guía de la miel, que se puede simular como:

$$x_{new} = x_{prey} + F \times r_7 \times \alpha \times d_i\quad (59)$$

$r_7$  es un número aleatorio entre 0 y 1.

#### G. Reptile Search Algorithm

El algoritmo Reptile Search (RSA) originalmente propuesto por Abualigah et al. [?] está basado en el comportamiento de los cocodrilos durante la caza. La ecuación 1 es generada de manera estocástica, y la mejor solución es considerada la más cercana al óptimo en cada iteración.

$$X = \begin{bmatrix} x_{1,1} & x_{1,2} & \dots & x_{1,n} \\ x_{2,1} & x_{2,2} & \dots & x_{2,n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{N,1} & x_{N,2} & \dots & x_{N,n} \end{bmatrix}\quad (60)$$

La fase de exploración está definida por:

$$\begin{aligned}x_{(i,j)}(t+1) = \\ \begin{cases} Best_j(t) - \eta_{(i,j)} \times \beta - R_{(i,j)}(t) \times rand, & t \leq \frac{T}{4} \\ Best_j(t) \times x_{(r_1,j)} \times ES(t) \times rand, & t \leq 2\frac{T}{4} \text{ and } t \geq \frac{T}{4} \end{cases}\end{aligned}\quad (61)$$

$$\eta_{(i,j)} = Best_j(t) \times P_{(i,j)}\quad (62)$$

$$R_{(i,j)} = \frac{Best_j(t) - x_{(r_2,j)}}{Best_j(t) + \epsilon}\quad (63)$$

$$ES(t) = 2 \times r_3 \times \left(1 - \frac{1}{T}\right)\quad (64)$$

$$P_{(i,j)} = \alpha + \frac{x_{(i,j)} - M_{(x_i)}}{Best_j(t) \times (UB_{(j)} - LB_{(j)}) + \epsilon}\quad (65)$$

$$M_{(x_i)} = \frac{1}{n} \sum_{j=1}^n x_{(i,j)}\quad (66)$$


#### H. Tuna Swarm Optimization

El algoritmo propuesto por Xie et al. [?]


#### V. EXPERIMENTACIÓN

#### VI. DISCUSIÓN DE RESULTADOS


#### VII. CONCLUSIÓN




(a) Image #1



(b) Image #2



(c) Image #3



(d) Image #4

Fig. 1: MRI test images used in the experiments.

TABLE I: Algorithms and Parameters

Algorithms	Parameters
BES	$c1 = c2 = 2$
	$\alpha = 2$
	$a = 10$
	$R = 1.5$
HHO	-
OPA	$p1, p2 = [0, 1]$
	$a = 0.01$
CSA	$fl = 2$
	$AP = 0.1$
GWO	$a = 2$ (linear decreasing)
HBA	$\beta = 6$
	$C = 2$
RSA	$\alpha = 0.1$
	$\beta = 0.1$
TSO	$z = 0.05$
	$a = 0.7$

TABLE II: Resultados de la métrica Fitness, Función Objetivo Kapur

Imagen	Dimension	Friedman Stat	P Value	RSA	HBA	OPA	BES	GWO	CSA	HHO	TSO
1	7	161,8777778	1,29109E-31	8	3	6	7	1	4	5	2
2	7	145,2222222	4,08628E-28	8	3	6	7	1	5	4	2
3	7	159,2222222	4,67596E-31	8	3	6	7	1	4	5	2
4	7	142,4888889	1,52941E-27	8	3	6	7	1	5	4	2
5	7	119,3333333	1,05467E-22	8	3	6	7	1	5	4	2
6	7	169,9444444	2,57907E-33	8	3	5	7	1	6	4	2
7	7	155,9111111	2,32458E-30	8	3	5	7	1	4	6	2
8	7	177,1666667	7,72397E-35	8	3	6	7	1	5	4	2
9	7	155,4222222	2,94537E-30	8	3	6	7	1	4	5	2
10	7	146,2222222	2,52074E-28	8	3	6	7	1	4	5	2
11	7	173,2222222	5,2505E-34	8	3	6	7	1	5	4	2
12	7	145,3777778	3,7905E-28	8	3	6	7	1	5	4	2
13	7	145,0555556	4,42884E-28	8	3	6	7	1	4	5	2
14	7	142,8111111	1,30909E-27	8	3	6	7	1	4	5	2
15	7	175,2888889	1,92379E-34	8	3	5	7	2	6	4	1
16	7	144,9444444	4,67301E-28	8	3	6	7	1	5	4	2
17	7	151,3555556	2,10763E-29	8	3	6	7	1	4	5	2
18	7	164,1777778	4,233E-32	8	3	6	7	1	5	4	2
19	7	135,4777778	4,49757E-26	8	3	6	7	1	4	5	2
20	7	177,2222222	7,5182E-35	8	3	5	7	2	6	4	1
1	8	137,6555556	1,57448E-26	8	3	5	7	1	4	6	2
2	8	140,7111111	3,60682E-27	8	3	5	7	1	4	6	2
3	8	146,1444444	2,61727E-28	8	3	6	7	1	4	5	2
4	8	150,8333333	2,71326E-29	8	3	6	7	2	5	4	1
5	8	133,9222222	9,51505E-26	8	3	5	7	1	4	6	2
6	8	172,7	6,76643E-34	8	3	5	7	2	6	4	1
7	8	148,8444444	7,09832E-29	8	3	6	7	1	4	5	2
8	8	175,5222222	1,71758E-34	8	3	6	7	2	5	4	1
9	8	156,1888889	2,03204E-30	8	3	6	7	1	4	5	2
10	8	155,5888889	2,71704E-30	8	3	5	7	1	4	6	2
11	8	176,3444444	1,15184E-34	8	3	6	7	1	5	4	2
12	8	145,9333333	2,8983E-28	8	3	6	7	1	4	5	2
13	8	147,0888889	1,6583E-28	8	3	5	7	1	4	6	2
14	8	136,1222222	3,29696E-26	8	3	6	7	1	4	5	2
15	8	174,5666667	2,73247E-34	8	3	5	7	2	6	4	1
16	8	150,4111111	3,32792E-29	8	3	6	7	1	4	5	2
17	8	143,2555556	1,0563E-27	8	3	6	7	1	4	5	2
18	8	142,6333333	1,4264E-27	8	3	6	7	1	5	4	2
19	8	142,0222222	1,91578E-27	8	3	6	7	1	4	5	2
20	8	173,2555556	5,16617E-34	8	3	5	7	2	6	4	1
1	9	146,7666667	1,93769E-28	8	3	5	7	1	4	6	2
2	9	131,8	2,64342E-25	8	3	6	7	1	5	4	2
3	9	119,1222222	1,167E-22	8	3	6	7	1	4	5	2
4	9	155,5222222	2,80617E-30	8	3	5	7	1	4	6	2
5	9	137,4555556	1,73385E-26	8	3	6	7	1	4	5	2
6	9	175,7555556	1,53347E-34	7	3	5	8	2	6	4	1
7	9	123,5444444	1,39867E-23	8	3	5	7	1	4	6	2
8	9	168,8444444	4,39904E-33	8	3	5	7	2	6	4	1
9	9	118,1777778	1,83509E-22	8	3	6	7	1	4	5	2
10	9	151,8	1,69991E-29	8	3	4	7	1	5	6	2
11	9	181,8444444	7,94424E-36	8	3	6	7	2	5	4	1
12	9	129,3444444	8,61546E-25	8	3	5	7	1	4	6	2
13	9	144,0222222	7,29493E-28	8	3	6	7	1	4	5	2
14	9	131,4888889	3,07041E-25	8	3	6	7	1	4	5	2
15	9	173,1555556	5,4233E-34	8	3	5	7	2	6	4	1
16	9	135,6	4,24035E-26	8	3	5	7	1	4	6	2
17	9	146,0888889	2,68847E-28	8	3	6	7	1	4	5	2
18	9	133,5333333	1,14749E-25	8	3	5	7	1	4	6	2
19	9	148,4	8,79959E-29	8	3	5	7	1	4	6	2
20	9	177,4444444	6,74845E-35	8	3	5	7	2	6	4	1



TABLE III: Resultados de la métrica Fitness, Función Objetivo Otsu

Imagen	Dimension	Friedman Stat	P Value	RSA	HBA	OPA	BES	GWO	CSA	HHO	TSO
1	7	147,2666667	1,52178E-28	8	3	6	7	2	4	5	1
2	7	163,9111111	4,81738E-32	8	3	6	7	1	5	4	2
3	7	158,5888889	6,35513E-31	8	3	6	7	2	4	5	1
4	7	150,3333333	3,45548E-29	8	3	6	7	1	4	5	2
5	7	166,5	1,3723E-32	8	3	6	7	1	4	5	2
6	7	179,8888889	2,0563E-35	8	3	6	7	2	5	4	1
7	7	142,1888889	1,76771E-27	8	3	6	7	2	4	5	1
8	7	164,2666667	4,0544E-32	8	3	7	6	2	5	4	1
9	7	144,3	6,37919E-28	8	3	6	7	2	4	5	1
10	7	151,8333333	1,67272E-29	8	3	6	7	2	5	4	1
11	7	163,9555556	4,71466E-32	8	3	6	7	2	5	4	1
12	7	160,9777778	1,99716E-31	8	3	6	7	1	4	5	2
13	7	163,3111111	6,44416E-32	8	3	6	7	1	5	4	2
14	7	146,7444444	1,95861E-28	8	3	6	7	1	4	5	2
15	7	172,4444444	7,66062E-34	8	3	6	7	2	5	4	1
16	7	165,4	2,33992E-32	8	3	6	7	1	5	4	2
17	7	144,3888889	6,11115E-28	8	3	5	7	1	4	6	2
18	7	162,2	1,10438E-31	8	3	6	7	1	4	5	2
19	7	154,2888889	5,09796E-30	8	3	6	7	2	4	5	1
20	7	174,5222222	2,79211E-34	8	3	7	6	2	5	4	1
1	8	155	3,61334E-30	8	3	6	7	2	5	4	1
2	8	147,0333333	1,70342E-28	8	3	6	7	2	5	4	1
3	8	151,9	1,61964E-29	8	3	6	7	1	4	5	2
4	8	139,0444444	8,05909E-27	8	3	5	7	1	4	6	2
5	8	150,5555556	3,10339E-29	8	3	5	7	1	4	6	2
6	8	172,3111111	8,1731E-34	8	3	6	7	2	5	4	1
7	8	149,7444444	4,59388E-29	8	3	6	7	1	4	5	2
8	8	180,9111111	1,25083E-35	8	3	7	6	2	5	4	1
9	8	158,7444444	5,89382E-31	8	3	6	7	2	5	4	1
10	8	153,4222222	7,75452E-30	8	3	6	7	1	4	5	2
11	8	173,7111111	4,14061E-34	8	3	6	7	2	5	4	1
12	8	162,7888889	8,30101E-32	8	3	6	7	2	5	4	1
13	8	158,9222222	5,40746E-31	8	3	6	7	2	5	4	1
14	8	166,4666667	1,39467E-32	8	3	6	7	2	5	4	1
15	8	170,6666667	1,81628E-33	8	3	6	7	2	5	4	1
16	8	153,8888889	6,18691E-30	8	3	6	7	2	5	4	1
17	8	171,8333333	1,03075E-33	8	3	6	7	2	5	4	1
18	8	148,8888889	6,94743E-29	8	3	5	7	1	4	6	2
19	8	152,2666667	1,35638E-29	8	3	5	7	1	4	6	2
20	8	165,0777778	2,73576E-32	8	3	7	6	2	5	4	1
1	9	162,9444444	7,69798E-32	8	3	6	7	2	5	4	1
2	9	165,1	2,70643E-32	8	3	6	7	1	5	4	2
3	9	143,0222222	1,18225E-27	8	3	6	7	2	4	5	1
4	9	157,7111111	9,72259E-31	8	3	6	7	1	5	4	2
5	9	152,9222222	9,87713E-30	8	3	6	7	1	4	5	2
6	9	174,6555556	2,61698E-34	8	3	6	7	2	5	4	1
7	9	156,9555556	1,40185E-30	8	3	6	7	1	5	4	2
8	9	165,1888889	2,59223E-32	8	3	6	7	2	5	4	1
9	9	153,5222222	7,38819E-30	8	3	6	7	2	4	5	1
10	9	151,2222222	2,24804E-29	8	3	6	7	1	5	4	2
11	9	161,6444444	1,4457E-31	8	3	7	6	2	5	4	1
12	9	155,4444444	2,91385E-30	8	3	6	7	2	4	5	1
13	9	161,9777778	1,23E-31	8	3	6	7	1	5	4	2
14	9	154,8	3,98065E-30	8	3	6	7	1	5	4	2
15	9	162,7222222	8,5737E-32	8	3	6	7	2	5	4	1
16	9	156,2666667	1,95694E-30	8	3	6	7	2	5	4	1
17	9	158,5333333	6,52849E-31	8	3	6	7	1	4	5	2
18	9	154,3	5,07062E-30	8	3	6	7	2	4	5	1
19	9	155,5666667	2,74643E-30	8	3	6	7	1	5	4	2
20	9	161,9333333	1,25679E-31	8	3	7	6	2	5	4	1

TABLE IV: Resultados de la métrica PSNR, Función Objetivo Kapur

Imagen	Dimension	Friedman Stat	P Value	RSA	HBA	OPA	BES	GWO	CSA	HHO	TSO
1	7	66,41111	7,82E-12	5	2	1	7	6	4	3	<b>8</b>
2	7	62,46667	4,85E-11	4	3	1	<b>8</b>	5	2	6	7
3	7	61,56667	7,34E-11	6	2	5	<b>8</b>	1	3	4	7
4	7	46,42222	7,23E-08	6	1	4	7	2	3	5	<b>8</b>
5	7	58,31111	3,28E-10	4	1	3	7	5	6	2	<b>8</b>
6	7	75,68889	1,04E-13	6	3	5	<b>8</b>	1	2	4	7
7	7	37	4,69E-06	6	1	5	<b>8</b>	3	2	4	7
8	7	75,53333	1,12E-13	6	4	3	<b>8</b>	1	2	5	7
9	7	66,42222	7,78E-12	6	5	3	7	1	2	4	<b>8</b>
10	7	33,62222	2,03E-05	6	1	3	7	4	5	2	<b>8</b>
11	7	76,63333	6,68E-14	6	5	2	<b>8</b>	3	1	4	7
12	7	43,81111	2,32E-07	6	1	2	7	3	5	4	<b>8</b>
13	7	45,82222	9,47E-08	6	2	5	7	1	3	4	<b>8</b>
14	7	38,73333	2,2E-06	5	1	2	7	4	6	3	<b>8</b>
15	7	74,42222	1,88E-13	6	3	1	<b>8</b>	2	4	5	7
16	7	29,25556	0,00013	6	3	1	<b>8</b>	2	4	5	7
17	7	43,78889	2,35E-07	5	1	3	<b>8</b>	2	6	4	7
18	7	64,92222	1,56E-11	6	4	1	<b>8</b>	2	3	5	7
19	7	59,23333	2,15E-10	6	4	5	7	1	2	3	<b>8</b>
20	7	72,98889	3,67E-13	6	2	5	<b>8</b>	1	3	4	7
1	8	36,13333	6,84E-06	4	1	5	7	3	6	2	<b>8</b>
1	9	34,93333	1,15E-05	6	1	2	7	4	3	5	<b>8</b>
2	8	43,75556	2,38E-07	4	1	3	7	2	5	6	<b>8</b>
2	9	44,67778	1,58E-07	6	3	1	7	2	4	5	<b>8</b>
3	8	31,51111	5E-05	6	2	5	7	3	1	4	<b>8</b>
3	9	40,13333	1,19E-06	6	1	5	7	4	2	3	<b>8</b>
4	8	60,55556	1,17E-10	6	2	3	7	4	1	5	<b>8</b>
4	9	55,14444	1,4E-09	6	2	4	7	1	3	5	<b>8</b>
5	8	63,84444	2,57E-11	3	1	2	7	5	6	4	<b>8</b>
5	9	51,34444	7,86E-09	6	2	3	7	1	4	5	<b>8</b>
6	8	75,14444	1,34E-13	6	4	3	<b>8</b>	1	2	5	7
6	9	98,37778	2,33E-18	6	3	1	<b>8</b>	2	4	5	7
7	8	59,46667	1,93E-10	6	4	2	7	1	3	5	<b>8</b>
7	9	51,22222	8,31E-09	6	3	2	<b>8</b>	1	4	5	7
8	8	85,26667	1,16E-15	6	4	2	<b>8</b>	1	3	5	7
8	9	97,92222	2,9E-18	6	4	5	<b>8</b>	1	2	3	7
9	8	51,15556	8,56E-09	6	4	3	<b>8</b>	1	2	5	7
9	9	35,36667	9,54E-06	6	3	4	<b>8</b>	1	2	5	7
10	8	41,4	6,78E-07	3	2	6	7	4	1	5	<b>8</b>
10	9	36,24444	6,52E-06	6	2	1	7	3	4	5	<b>8</b>
11	8	84,13333	1,97E-15	6	4	3	<b>8</b>	2	1	5	7
11	9	74,91111	1,49E-13	5	4	1	<b>8</b>	2	3	6	7
12	8	49,05556	2,21E-08	6	1	2	7	4	5	3	<b>8</b>
12	9	49,11111	2,16E-08	5	1	4	7	3	2	6	<b>8</b>
13	8	52,9	3,88E-09	6	2	1	7	3	5	4	<b>8</b>
13	9	60,2	1,38E-10	5	4	3	<b>8</b>	2	1	6	7
14	8	30,15556	8,89E-05	4	3	1	7	2	6	5	<b>8</b>
14	9	35,9	7,57E-06	4	5	3	7	2	6	1	<b>8</b>
15	8	84,32222	1,8E-15	6	3	5	<b>8</b>	2	1	4	7
15	9	97,3	3,89E-18	6	3	4	<b>8</b>	1	2	5	7
16	8	40,46667	1,02E-06	5	2	4	7	1	3	6	<b>8</b>
16	9	42,8	3,65E-07	6	1	4	7	2	3	5	<b>8</b>
17	8	52,36667	4,94E-09	6	4	1	<b>8</b>	3	2	5	7
17	9	72,62222	4,35E-13	6	4	1	7	3	2	5	<b>8</b>
18	8	37,64444	3,54E-06	5	3	1	<b>8</b>	4	2	6	7
18	9	47,55556	4,35E-08	6	2	1	<b>8</b>	3	4	5	7
19	8	64,31111	2,07E-11	4	2	6	<b>8</b>	1	3	5	7
19	9	35,72222	8,18E-06	6	2	4	7	1	3	5	<b>8</b>
20	8	89,02222	1,96E-16	6	3	4	<b>8</b>	2	1	5	7
20	9	80,68889	9,97E-15	6	4	2	<b>8</b>	3	1	5	7

TABLE V: Resultados de la métrica PSNR, Función Objetivo Otsu

Imagen	Dimension	Friedman Stat	P Value	RSA	HBA	OPA	BES	GWO	CSA	HHO	TSO
1	7	37,77777778	3,34E-06	3	4	1	<b>8</b>	2	6	5	7
1	8	64,91111111	1,57E-11	6	3	2	7	1	4	5	<b>8</b>
1	9	51,77777778	6,46E-09	6	2	1	7	3	4	5	<b>8</b>
2	7	58,6	2,87E-10	6	2	5	7	1	3	4	<b>8</b>
2	8	65,33333333	1,29E-11	6	2	4	7	1	5	3	<b>8</b>
2	9	67,23333333	5,34E-12	6	2	5	7	1	4	3	<b>8</b>
3	7	78,37777778	2,95E-14	6	4	3	7	1	2	5	<b>8</b>
3	8	47,01111111	5,55E-08	5	3	1	7	2	4	6	<b>8</b>
3	9	80,98888889	8,66E-15	6	3	4	7	1	2	5	<b>8</b>
4	7	61,6	7,23E-11	6	2	5	7	1	3	4	<b>8</b>
4	8	25,04444444	0,000745	6	4	1	7	3	2	5	<b>8</b>
4	9	58,53333333	2,96E-10	5	1	2	7	3	4	6	<b>8</b>
5	7	75,12222222	1,35E-13	6	3	4	7	1	2	5	<b>8</b>
5	8	70,4	1,23E-12	6	3	2	7	1	4	5	<b>8</b>
5	9	75,48888889	1,14E-13	6	2	3	7	1	4	5	<b>8</b>
6	7	31,53333333	4,96E-05	<b>8</b>	6	7	1	3	2	5	4
6	8	35,75555556	8,06E-06	<b>8</b>	4	5	2	3	1	6	7
6	9	29,06666667	0,000141	<b>8</b>	4	7	1	3	6	5	2
7	7	60,2	1,38E-10	6	5	3	7	1	2	4	<b>8</b>
7	8	33,81111111	1,87E-05	6	4	2	7	1	3	5	<b>8</b>
7	9	67,7	4,3E-12	6	2	5	7	4	1	3	<b>8</b>
8	7	30,5	7,69E-05	3	6	7	1	4	2	5	<b>8</b>
8	8	26,42222222	0,000423	7	4	<b>8</b>	3	2	1	6	5
8	9	23,24444444	0,001545	3	6	4	1	2	5	7	<b>8</b>
9	7	72,63333333	4,33E-13	6	4	3	7	1	2	5	<b>8</b>
9	8	64,28888889	2,09E-11	6	3	1	7	2	4	5	<b>8</b>
9	9	71,54444444	7,2E-13	6	4	2	7	1	3	5	<b>8</b>
10	7	47,15555556	5,21E-08	5	2	3	7	1	4	6	<b>8</b>
10	8	59,4	1,99E-10	5	2	1	7	3	4	6	<b>8</b>
10	9	58,03333333	3,72E-10	6	4	2	7	1	3	5	<b>8</b>
11	7	15,01111111	0,035857	7	5	4	6	1	2	3	<b>8</b>
11	8	27,64444444	0,000255	7	4	3	6	1	2	5	<b>8</b>
11	9	30,44444444	7,87E-05	7	4	3	6	2	1	5	<b>8</b>
12	7	60,22222222	1,36E-10	6	2	4	7	1	3	5	<b>8</b>
12	8	31,42222222	5,2E-05	6	3	1	7	2	5	4	<b>8</b>
12	9	38,84444444	2,09E-06	6	2	3	7	1	5	4	<b>8</b>
13	7	70,26666667	1,3E-12	5	4	3	<b>8</b>	1	2	6	7
13	8	56,07777778	9,11E-10	2	1	5	<b>8</b>	4	3	6	7
13	9	77,35555556	4,76E-14	4	5	2	<b>8</b>	1	3	6	7
14	7	42,95555556	3,4E-07	6	1	3	7	2	5	4	<b>8</b>
14	8	58,35555556	3,21E-10	6	2	4	<b>8</b>	1	5	3	7
14	9	67,46666667	4,79E-12	6	5	1	<b>8</b>	2	4	3	7
15	7	33,9	1,8E-05	<b>8</b>	5	7	1	3	2	6	4
15	8	26,34444444	0,000437	5	4	<b>8</b>	2	3	1	7	6
15	9	28,42222222	0,000184	7	5	2	1	3	4	6	<b>8</b>
16	7	72,4	4,83E-13	5	3	1	7	4	2	6	<b>8</b>
16	8	84,51111111	1,65E-15	2	5	1	7	4	3	6	<b>8</b>
16	9	68,97777778	2,38E-12	5	2	1	7	3	4	6	<b>8</b>
17	7	57,07777778	5,77E-10	6	2	4	7	1	5	3	<b>8</b>
17	8	70,61111111	1,11E-12	6	4	5	7	1	2	3	<b>8</b>
17	9	62,11111111	5,71E-11	6	3	4	7	1	2	5	<b>8</b>
18	7	66,66666667	6,95E-12	6	3	4	7	1	2	5	<b>8</b>
18	8	94,31111111	1,61E-17	6	2	3	7	1	4	5	<b>8</b>
18	9	86,67777778	5,94E-16	6	3	4	7	1	2	5	<b>8</b>
19	7	41,15555556	7,56E-07	6	3	5	7	1	4	2	<b>8</b>
19	8	50,17777778	1,33E-08	5	1	6	<b>8</b>	3	2	4	7
19	9	37,72222222	3,42E-06	6	2	4	7	1	5	3	<b>8</b>
20	7	38,63333333	2,3E-06	2	7	3	1	6	4	5	<b>8</b>
20	8	39,36666667	1,66E-06	5	6	2	1	3	4	7	<b>8</b>
20	9	34,65555556	1,3E-05	3	7	5	1	4	2	6	<b>8</b>

TABLE VI: Resultados de la métrica PSNR, Función Objetivo Otsu

Imagen	Dimension	Friedman Stat	P Value	RSA	HBA Rank	OPA	BES	GWO	CSA	HHO	TSO
1	7	41,77778	5,74E-07	2	6	1	<b>8</b>	4	3	5	7
1	8	57,72222	4,29E-10	2	4	1	7	3	5	6	<b>8</b>
1	9	34,54444	1,36E-05	2	3	1	7	4	5	6	<b>8</b>
2	7	35,44444	9,23E-06	1	3	4	<b>8</b>	2	6	5	7
2	8	56,96667	6,07E-10	1	5	3	7	6	2	4	<b>8</b>
2	9	32,02222	4,02E-05	3	1	6	<b>8</b>	2	5	4	7
3	7	66,5	7,51E-12	4	5	3	7	1	2	6	<b>8</b>
3	8	37,62222	3,57E-06	2	5	1	<b>8</b>	3	4	6	7
3	9	55,56667	1,15E-09	6	5	3	<b>8</b>	1	2	4	7
4	7	53,08889	3,56E-09	6	3	5	<b>8</b>	1	2	4	7
4	8	29,51111	0,000117	5	3	1	7	4	2	6	<b>8</b>
4	9	49,1	2,17E-08	5	2	1	7	3	4	6	<b>8</b>
5	7	54,06667	2,28E-09	5	4	2	7	1	3	6	<b>8</b>
5	8	51,5	7,32E-09	6	4	2	<b>8</b>	3	1	5	7
5	9	59,1	2,28E-10	6	3	4	<b>8</b>	1	2	5	7
6	7	81,54444	6,67E-15	6	3	4	<b>8</b>	1	2	5	7
6	8	93,4	2,47E-17	6	3	4	<b>8</b>	1	2	5	7
6	9	93,96667	1,89E-17	7	2	4	<b>8</b>	1	3	5	6
7	7	62,1	5,74E-11	6	5	3	7	2	1	4	<b>8</b>
7	8	43,64444	2,5E-07	4	5	1	7	2	3	6	<b>8</b>
7	9	57,86667	4,02E-10	6	2	5	7	3	1	4	<b>8</b>
8	7	79,25556	1,95E-14	4	3	6	<b>8</b>	1	2	5	7
8	8	104,8556	1,07E-19	6	3	4	<b>8</b>	1	2	5	7
8	9	81,4	7,14E-15	6	2	4	<b>8</b>	1	3	5	7
9	7	66,44444	7,7E-12	6	4	2	<b>8</b>	3	1	5	7
9	8	75,42222	1,18E-13	5	4	1	<b>8</b>	2	3	6	7
9	9	73,3	3,17E-13	4	5	1	<b>8</b>	2	3	6	7
10	7	37,74444	3,39E-06	1	5	3	7	2	4	6	<b>8</b>
10	8	35,94444	7,43E-06	1	4	2	<b>8</b>	5	3	6	7
10	9	50,28889	1,27E-08	4	5	1	7	2	3	6	<b>8</b>
11	7	74,88889	1,51E-13	6	4	3	<b>8</b>	1	2	5	7
11	8	81,47778	6,88E-15	6	4	3	<b>8</b>	1	2	5	7
11	9	76,48889	7,15E-14	6	3	4	<b>8</b>	1	2	5	7
12	7	51,77778	6,46E-09	5	4	2	7	1	3	6	<b>8</b>
12	8	32,31111	3,56E-05	5	2	1	7	6	3	4	<b>8</b>
12	9	22,37778	0,002186	6	3	1	7	2	5	4	<b>8</b>
13	7	75,4	1,19E-13	1	5	2	<b>8</b>	4	3	6	7
13	8	60,03333	1,49E-10	1	4	2	<b>8</b>	5	3	6	7
13	9	80,47778	1,1E-14	1	5	2	<b>8</b>	3	4	6	7
14	7	40,68889	9,29E-07	6	2	1	7	5	4	3	<b>8</b>
14	8	49,18889	2,08E-08	6	2	1	<b>8</b>	5	4	3	7
14	9	76,83333	6,08E-14	4	5	1	<b>8</b>	6	3	2	7
15	7	81,43333	7,02E-15	6	3	5	<b>8</b>	1	2	4	7
15	8	95,51111	9,1E-18	6	3	4	<b>8</b>	1	2	5	7
15	9	88,88889	2,09E-16	5	4	3	<b>8</b>	1	2	6	7
16	7	72,27778	5,11E-13	2	4	1	7	5	3	6	<b>8</b>
16	8	88,22222	2,87E-16	1	5	2	7	4	3	6	<b>8</b>
16	9	76,57778	6,85E-14	2	3	1	7	6	4	5	<b>8</b>
17	7	34,88889	1,17E-05	3	4	5	<b>8</b>	1	2	6	7
17	8	55,3	1,3E-09	5	6	2	7	3	1	4	<b>8</b>
17	9	38,46667	2,47E-06	5	4	1	7	2	3	6	<b>8</b>
18	7	31,06667	6,04E-05	4	6	3	7	2	1	5	<b>8</b>
18	8	56,66667	6,96E-10	5	4	1	7	2	3	6	<b>8</b>
18	9	61,24444	8,51E-11	4	5	3	7	1	2	6	<b>8</b>
19	7	28,15556	0,000206	6	3	5	<b>8</b>	1	2	4	7
19	8	46,15556	8,15E-08	4	3	5	<b>8</b>	1	2	6	7
19	9	34,07778	1,67E-05	5	3	1	7	2	4	6	<b>8</b>
20	7	76,18889	8,22E-14	6	4	3	<b>8</b>	1	2	5	7
20	8	93,43333	2,44E-17	6	4	2	<b>8</b>	1	3	5	7
20	9	93,24444	2,66E-17	6	3	5	<b>8</b>	1	2	4	7

Images	Statistic	K	RSA	HBA	OPA	BES	GWO	CSA	HHO	TSO
F1	mean	7	16.8415	18.6008	<b>19.0378</b>	12.4259	16.5949	17.2898	17.8995	10.3428
	std	7	2.8091	2.5322	2.1069	4.3029	<b>1.2547</b>	1.8363	2.1700	7.1366
	mean	8	18.0848	<b>18.6095</b>	17.9678	13.7862	18.1496	17.5765	18.3118	11.6553
	std	8	3.4809	2.3980	2.2809	4.3784	<b>0.9968</b>	2.1366	1.7264	7.8673
	mean	9	17.9054	<b>19.1277</b>	19.0474	13.4510	18.3593	18.3750	18.2633	12.4155
F2	std	9	3.2908	2.5047	3.2909	5.1280	<b>1.8754</b>	2.8592	2.2304	8.0392
	mean	7	17.6955	17.7521	<b>18.2468</b>	11.8722	17.4575	17.9066	17.1877	12.7406
	std	7	2.9943	2.5984	2.1936	3.5418	<b>1.2993</b>	2.1529	2.1230	6.8113
	mean	8	18.3312	<b>19.5930</b>	18.9259	13.5174	19.0829	18.2526	17.8959	11.8164
	std	8	3.0435	2.3673	3.0180	4.6205	<b>1.4831</b>	2.3885	2.1991	7.9298
F3	mean	9	18.3901	19.3131	<b>20.1305</b>	13.0511	19.3892	19.0729	18.9121	12.4084
	std	9	3.1074	2.7224	3.6887	4.5721	2.2127	2.3491	<b>2.1083</b>	8.6260
	mean	7	17.7451	19.9906	<b>20.6244</b>	12.0663	20.2754	20.0820	19.5346	12.4502
	std	7	3.0708	2.2741	2.4050	3.8757	1.9929	2.2338	<b>1.9294</b>	8.0514
	mean	8	19.7779	20.4541	<b>21.2572</b>	14.5468	20.2769	20.5124	19.0241	14.7632
F4	std	8	2.9498	2.0158	2.3434	4.9122	1.7624	2.3371	<b>1.3585</b>	8.3448
	mean	9	18.2264	21.0774	<b>21.5497</b>	14.3670	20.9327	20.7083	20.4853	15.9960
	std	9	3.3583	2.6495	3.0459	4.6386	2.5619	2.5215	<b>2.2386</b>	8.6824
	mean	7	16.6854	<b>18.0298</b>	17.7110	13.7909	17.1674	17.0721	17.7907	13.4420
	std	7	3.2059	2.0838	2.5671	3.8161	<b>1.5386</b>	1.6440	2.0412	6.4489
F5	mean	8	18.1434	18.3467	17.7278	12.6613	18.0057	<b>18.6314</b>	17.8556	10.4756
	std	8	3.3210	2.3451	2.5039	5.1740	<b>1.2898</b>	2.1202	1.4007	7.9066
	mean	9	18.2020	18.7986	<b>19.6242</b>	14.1962	18.5082	18.4950	18.4662	12.6127
	std	9	3.0850	<b>2.0593</b>	2.7600	4.4468	2.0766	2.2396	2.2794	7.8680
	mean	7	19.9797	<b>20.7853</b>	20.2874	14.0884	19.5769	19.4854	20.6011	13.9151
F6	std	7	3.2007	3.0760	3.2299	3.5047	<b>0.9107</b>	1.5160	2.5662	7.9552
	mean	8	21.5042	<b>22.3609</b>	21.5720	14.5709	21.3971	20.4850	21.4152	11.9827
	std	8	3.6149	2.4033	3.1826	4.6213	<b>1.1041</b>	1.8459	2.2882	9.3253
	mean	9	20.0517	23.2850	23.0566	16.1048	<b>24.0167</b>	22.8623	21.8122	15.8950
	std	9	3.5591	2.7520	3.0434	5.2577	<b>1.9841</b>	2.8436	3.1287	9.6926
F7	mean	7	20.6693	23.2606	22.0721	15.7197	<b>23.8192</b>	22.8669	22.6973	18.1824
	std	7	3.1633	2.5617	2.6123	4.4421	<b>2.2950</b>	2.5938	2.6450	9.0340
	mean	8	21.1467	22.2468	21.3566	16.9602	21.8639	<b>23.0398</b>	21.8255	15.3021
	std	8	3.7913	3.1455	3.0254	5.0915	3.2947	3.2624	<b>2.4804</b>	9.7291
	mean	9	22.4474	<b>24.4998</b>	22.9128	17.0512	23.0312	23.3909	23.0746	14.3474
F8	std	9	3.2424	<b>2.7176</b>	3.6855	4.6108	2.8298	3.2192	2.7754	10.7931
	mean	7	20.7399	<b>23.1695</b>	22.8706	17.8034	23.0240	22.9262	22.3585	15.7602
	std	7	2.5718	0.9245	1.5267	4.4513	<b>0.8458</b>	1.8475	1.8810	9.7020
	mean	8	21.4795	23.9293	23.7784	17.0071	23.6954	<b>24.0956</b>	23.2941	14.6882
	std	8	3.2075	2.5921	<b>2.0351</b>	5.0646	2.1880	2.1871	2.1978	10.5986
F9	mean	9	21.5326	24.4992	23.9838	18.1621	<b>26.1681</b>	24.4164	23.2119	17.4642
	std	9	4.1685	3.0110	3.3602	4.6997	<b>1.8117</b>	3.2413	2.9816	10.0060
	mean	7	21.3814	<b>23.3332</b>	22.4076	17.0849	22.7261	23.0590	22.5137	19.7571
	std	7	3.2222	1.4353	2.2995	5.1669	<b>0.9122</b>	1.8425	1.5988	7.4659
	mean	8	22.0001	23.5209	23.8607	16.5921	<b>24.2525</b>	23.6137	22.2154	13.6418
F10	std	8	2.6945	2.5169	2.2092	4.1158	<b>1.3417</b>	2.2145	2.3931	10.6635
	mean	9	22.2461	24.8963	24.9505	16.9221	<b>25.1433</b>	23.7688	23.6335	17.0786
	std	9	3.5347	2.7869	2.6024	4.9229	<b>2.4194</b>	2.9505	3.3102	10.5165
	mean	7	20.1803	22.2854	23.0773	15.4640	<b>23.8754</b>	23.2541	22.5442	15.0946
	std	7	2.7947	2.7724	2.3788	4.7016	<b>0.9590</b>	2.0764	2.5152	10.3081
F11	mean	8	21.1959	23.1391	23.3927	16.8906	<b>25.2875</b>	24.3720	22.3899	18.4263
	std	8	4.3743	3.4381	2.6306	4.9833	<b>1.8795</b>	2.7023	3.8730	9.9244
	mean	9	22.6317	23.7265	23.7052	17.6489	<b>24.7845</b>	24.4932	23.6907	20.4074
	std	9	3.6934	3.4279	2.8946	4.9561	3.2292	3.0540	<b>2.6854</b>	9.6552
	mean	7	6.1291	7.1784	7.2552	3.5298	<b>7.4626</b>	7.2699	6.8447	5.6470
F12	std	7	0.7984	0.8253	1.5042	0.7706	<b>0.7154</b>	1.4624	1.0567	2.6758
	mean	8	6.3461	7.2454	7.5497	3.6300	<b>7.8431</b>	7.2986	7.2126	5.2227
	std	8	0.7687	1.0459	1.4590	0.6360	<b>0.5821</b>	1.1884	0.9589	3.0025
	mean	9	6.4842	7.0930	7.0471	3.5539	<b>7.7831</b>	7.7431	7.3405	4.3366
	std	9	1.1443	0.9667	1.0019	<b>0.5312</b>	0.5959	1.1869	0.8942	2.7422
F13	mean	7	6.4445	7.3550	6.9324	3.6732	<b>7.4540</b>	7.1552	7.0922	4.5032
	std	7	1.1505	0.7572	1.1664	1.0091	<b>0.5424</b>	1.1872	0.8176	3.0360
	mean	8	6.3156	7.3493	7.1112	3.3340	7.5179	<b>7.7656</b>	6.7853	5.4761
	std	8	1.0754	0.8631	1.3560	0.5934	<b>0.4903</b>	1.3398	0.7194	2.8493
	mean	9	6.5869	7.1658	7.3937	3.1366	7.3381	<b>7.4069</b>	6.7024	5.6625
F14	std	9	1.0741	0.8416	0.8749	<b>0.5240</b>	0.5634	1.1978	0.8689	2.5911
	mean	7	7.0686	7.7754	8.1365	4.0964	8.0522	<b>8.3804</b>	7.8493	6.0913
	std	7	1.1652	0.8682	1.2286	0.6482	0.4053	1.3458	1.3618	2.9274
	mean	8	7.0931	8.0133	8.2666	3.8474	8.2780	<b>8.5364</b>	7.3846	5.5350
	std	8	1.4114	1.0422	1.3605	<b>0.5495</b>	0.6422	1.4131	1.0465	3.4280
F15	mean	9	7.5467	7.8703	<b>8.6432</b>	3.9549	8.3714	8.3053	7.5370	6.0505
	std	9	1.3977	1.0315	1.6155	<b>0.6770</b>	0.7507	1.2538	0.9581	3.2650
	mean	7	6.5924	7.3494	<b>7.7607</b>	3.1956	7.6020	7.2196	6.8877	5.5543
	std	7	1.1402	0.7810	1.4607	<b>0.4911</b>	0.5832	1.2114	0.8875	3.1167
	mean	8	6.5684	7.5428	7.2584	3.3082	7.9267	<b>8.1085</b>	7.3569	5.7577
F16	std	8	1.3943	0.9825	0.9761	<b>0.6251</b>	0.8217	1.3676	0.9728	2.8658
	mean	9	6.7882	7.5948	7.5216	3.5029	<b>8.3422</b>	7.6887	7.1790	4.4391
	std	9	1.0017	1.1662	1.2660	<b>0.6337</b>	0.8536	1.3124	0.9522	3.0055
	mean	7	6.5510	7.1450	7.0644	3.3778	<b>7.5759</b>	7.3813	7.0834	4.8632
	std	7	1.0767	0.9111	1.4721	<b>0.3754</b>	0.4964	1.1789	1.2881	2.9438
F17	mean	8	6.6346	7.3565	7.4921	3.5044	<b>7.6962</b>	7.6315	6.8183	5.3720
	std	8	1.2828	1.0218	1.1761	<b>0.6246</b>	0.6671	1.2077	0.9801	3.1041
	mean	9	6.5924	7.3494	<b>7.7607</b>	3.1956	7.6020	7.2196	6.8877	5.5543

TABLE VII: Resultados de la métrica SSIM, Funsión Objetivo Kapur

Imagen	Dimension	Friedman Stat	P Value	RSA	HBA	OPA	BES	GWO	CSA	HHO	TSO
1	7	78,73333333	2,5E-14	6	1	2	7	3	5	4	<b>8</b>
2	7	91,86666667	5,12E-17	6	4	2	7	1	3	5	<b>8</b>
3	7	80,42222222	1,13E-14	6	2	4	7	1	3	5	<b>8</b>
4	7	63,6	2,87E-11	6	2	4	7	1	3	5	<b>8</b>
5	7	74,63333333	1,7E-13	6	1	5	7	2	3	4	<b>8</b>
6	7	51,77777778	6,46E-09	6	2	5	7	3	4	1	<b>8</b>
7	7	50,95555556	9,37E-09	6	2	5	<b>8</b>	1	4	3	7
8	7	22,6	0,002001	6	1	5	<b>8</b>	2	4	3	7
9	7	63,72222222	2,72E-11	6	2	4	7	1	3	5	<b>8</b>
10	7	64,48888889	1,9E-11	6	1	5	7	2	3	4	<b>8</b>
11	7	65,82222222	1,03E-11	6	5	3	<b>8</b>	2	1	4	7
12	7	63,5	3,01E-11	6	3	1	7	4	2	5	<b>8</b>
13	7	74,42222222	1,88E-13	6	2	5	7	1	3	4	<b>8</b>
14	7	49,54444444	1,77E-08	6	1	3	7	2	4	5	<b>8</b>
15	7	41,25555556	7,23E-07	6	2	1	<b>8</b>	5	4	3	7
16	7	62,22222222	5,43E-11	6	2	3	<b>8</b>	1	4	5	7
17	7	85,48888889	1,04E-15	6	2	5	7	1	3	4	<b>8</b>
18	7	97,07777778	4,32E-18	6	2	5	7	1	3	4	<b>8</b>
19	7	78,73333333	2,5E-14	6	2	5	7	1	3	4	<b>8</b>
20	7	44,84444444	1,47E-07	6	2	5	7	3	4	1	<b>8</b>
1	8	57,74444444	4,25E-10	6	2	4	7	1	5	3	<b>8</b>
1	9	71,43333333	7,58E-13	6	2	4	7	1	3	5	<b>8</b>
2	8	71,07777778	8,95E-13	6	2	4	7	1	3	5	<b>8</b>
2	9	69,21111111	2,13E-12	6	3	2	7	1	4	5	<b>8</b>
3	8	63,95555556	2,44E-11	6	3	5	7	1	2	4	<b>8</b>
3	9	58,05555556	3,69E-10	6	1	5	7	2	3	4	<b>8</b>
4	8	65,73333333	1,07E-11	6	2	5	7	1	4	3	<b>8</b>
4	9	64,65555556	1,76E-11	6	2	4	7	1	3	5	<b>8</b>
5	8	72,7	4,2E-13	6	2	4	7	1	3	5	<b>8</b>
5	9	82,75555556	3,77E-15	6	2	4	7	1	3	5	<b>8</b>
6	8	41,24444444	7,27E-07	6	3	1	<b>8</b>	2	4	5	7
6	9	49,66666667	1,68E-08	6	2	1	7	3	5	4	<b>8</b>
7	8	96,34444444	6,13E-18	6	4	3	7	1	2	5	<b>8</b>
7	9	65,21111111	1,36E-11	6	2	4	7	1	3	5	<b>8</b>
8	8	65,12222222	1,42E-11	<b>8</b>	4	3	7	1	5	2	6
8	9	41,77777778	5,74E-07	6	4	5	7	2	1	3	<b>8</b>
9	8	56,71111111	6,82E-10	6	3	4	7	1	2	5	<b>8</b>
9	9	51,52222222	7,25E-09	6	3	2	7	1	4	5	<b>8</b>
10	8	80,56666667	1,06E-14	6	2	5	7	1	3	4	<b>8</b>
10	9	60,37777778	1,27E-10	6	3	2	7	1	4	5	<b>8</b>
11	8	72,38888889	4,85E-13	6	3	4	<b>8</b>	1	2	5	7
11	9	51,26666667	8,14E-09	6	5	2	<b>8</b>	1	4	3	7
12	8	84,63333333	1,56E-15	6	4	5	7	1	3	2	<b>8</b>
12	9	67,25555556	5,29E-12	6	2	4	7	1	3	5	<b>8</b>
13	8	65,17777778	1,39E-11	6	2	3	7	1	4	5	<b>8</b>
13	9	65,54444444	1,17E-11	5	2	4	<b>8</b>	1	3	6	7
14	8	72,83333333	3,95E-13	6	3	2	7	1	5	4	<b>8</b>
14	9	58,94444444	2,45E-10	6	5	2	7	1	4	3	<b>8</b>
15	8	49,47777778	1,83E-08	5	4	6	<b>8</b>	2	1	3	7
15	9	50,67777778	1,06E-08	6	2	5	7	1	3	4	<b>8</b>
16	8	57,13333333	5,62E-10	6	3	4	7	1	2	5	<b>8</b>
16	9	51,41111111	7,63E-09	6	2	4	7	1	3	5	<b>8</b>
17	8	91,21111111	6,98E-17	6	3	4	<b>8</b>	1	2	5	7
17	9	88,55555556	2,45E-16	6	3	2	7	1	4	5	<b>8</b>
18	8	95,01111111	1,15E-17	6	2	4	7	1	3	5	<b>8</b>
18	9	89,18888889	1,82E-16	6	2	4	7	1	3	5	<b>8</b>
19	8	58,48888889	3,02E-10	6	2	5	7	1	3	4	<b>8</b>
19	9	49,13333333	2,14E-08	6	2	4	7	1	3	5	<b>8</b>
20	8	42,68888889	3,83E-07	5	3	6	7	2	1	4	<b>8</b>
20	9	26,12222222	0,000479	6	4	1	<b>8</b>	2	3	5	7

TABLE VIII: Resultados de la métrica Fitness, Función Objetivo Otsu

Images	K		BES	HHO	OPA	CSA	GWO	HBA	RSA	TSO
Image #1	7	mean	12.238	17.666	17.967	17.635	17.821	17.810	16.697	12.161
		std	3.033	1.501	2.056	2.224	1.515	1.557	1.655	7.373
	8	mean	13.236	18.923	18.817	17.824	18.748	18.481	17.785	12.140
		std	4.095	1.304	2.150	2.762	1.053	1.619	1.839	8.462
	9	mean	13.338	19.436	20.242	18.760	19.213	19.249	19.097	12.407
		std	3.199	1.253	1.866	2.602	1.573	1.258	2.558	8.033
Image #2	7	mean	11.907	18.059	18.191	17.708	18.048	17.868	17.691	11.735
		std	2.884	0.755	2.228	1.808	0.938	1.261	2.016	7.746
	8	mean	12.632	18.586	19.253	18.051	18.899	18.832	18.082	14.454
		std	3.292	1.204	2.318	2.516	1.099	1.515	1.932	7.804
	9	mean	13.419	19.414	18.924	19.652	19.699	19.838	19.342	12.690
		std	3.734	1.383	2.519	2.604	1.533	2.317	2.715	8.573
Image #3	7	mean	13.691	18.109	18.874	18.696	17.835	18.616	17.729	13.762
		std	3.712	1.140	2.061	2.098	1.024	1.881	2.498	6.942
	8	mean	15.980	18.547	19.734	18.889	19.143	19.434	18.964	14.728
		std	4.252	1.805	2.101	2.274	1.548	1.948	1.918	7.651
	9	mean	14.799	19.884	19.848	20.348	19.605	19.686	19.837	10.611
		std	3.870	1.614	2.257	2.261	1.610	2.503	2.633	8.585
Image #4	7	mean	13.853	18.526	19.118	18.989	18.037	18.637	17.924	13.775
		std	3.842	1.679	1.851	1.965	1.200	2.136	2.037	7.714
	8	mean	14.264	18.802	19.678	19.300	19.038	19.495	19.248	13.932
		std	3.380	1.648	1.758	2.019	0.843	1.650	2.293	8.103
	9	mean	14.831	19.868	19.204	19.558	20.612	20.155	19.733	12.917
		std	3.605	1.589	2.572	2.341	1.182	1.836	2.561	9.141

TABLE IX: Resultados de la métrica SSIM

Images	K		BES	HHO	OPA	CSA	GWO	HBA	RSA	TSO
Image #1	7	mean	0.518	0.645	0.641	0.637	0.657	0.656	0.628	0.465
		std	0.065	0.015	0.024	0.029	0.015	0.014	0.027	0.246
	8	mean	0.539	0.670	0.664	0.649	0.680	0.673	0.654	0.439
		std	0.071	0.016	0.027	0.034	0.012	0.020	0.025	0.295
	9	mean	0.558	0.689	0.683	0.659	0.690	0.692	0.669	0.465
		std	0.063	0.013	0.018	0.033	0.017	0.012	0.032	0.272
Image #2	7	mean	0.518	0.669	0.658	0.651	0.678	0.675	0.651	0.448
		std	0.074	0.012	0.024	0.025	0.010	0.014	0.022	0.275
	8	mean	0.547	0.686	0.677	0.666	0.703	0.700	0.670	0.519
		std	0.084	0.018	0.031	0.035	0.013	0.016	0.028	0.275
	9	mean	0.567	0.702	0.689	0.692	0.721	0.719	0.695	0.446
		std	0.078	0.026	0.033	0.036	0.015	0.026	0.029	0.303
Image #3	7	mean	0.451	0.524	0.523	0.521	0.537	0.535	0.507	0.455
		std	0.053	0.014	0.023	0.020	0.007	0.012	0.030	0.130
	8	mean	0.486	0.541	0.539	0.533	0.552	0.554	0.538	0.465
		std	0.052	0.015	0.020	0.026	0.012	0.014	0.025	0.136
	9	mean	0.493	0.561	0.552	0.553	0.564	0.565	0.551	0.387
		std	0.046	0.016	0.022	0.018	0.014	0.017	0.020	0.161
Image #4	7	mean	0.425	0.526	0.530	0.524	0.529	0.530	0.520	0.418
		std	0.084	0.020	0.028	0.031	0.010	0.030	0.032	0.162
	8	mean	0.447	0.547	0.554	0.534	0.564	0.560	0.541	0.435
		std	0.077	0.026	0.024	0.040	0.012	0.026	0.036	0.181
	9	mean	0.462	0.571	0.548	0.560	0.592	0.584	0.564	0.415
		std	0.070	0.028	0.045	0.034	0.020	0.024	0.039	0.203